

深层动态自组织记忆（Deep Dynamic SOM）：LLM 的认知增强记忆机制

作者：[Leon Hollande、Jocelyn Liu]

摘要：针对当前大语言模型（Large Language Model, LLM）仅依赖 KV Cache 短期记忆、缺乏长期知识沉淀与概念抽象能力、易出现灾难性遗忘等核心痛点，本文提出一种深层动态自组织记忆（Deep Dynamic Self-Organizing Map, Deep Dynamic SOM）机制，将自组织映射（SOM）与辩证推理架构深度融合，构建“短期缓存-长期记忆-动态交互”的双重记忆体系。基于 DE-T-5Y（Five-Element Deep Dialectical Enhanced Transformer）自研大模型的实测数据，验证该机制在记忆利用率、长程关联捕捉、复杂推理精度等方面的提升效果。实验表明，Deep Dynamic SOM 通过 16,384 槽位的长期记忆存储、稀疏检索与动态更新机制，可有效弥补传统 Transformer 记忆缺陷，在 WikiText-CN 语言建模任务中使困惑度（PPL）降至 5.48，在 GSM8K 数学推理任务中准确率达到 78.2%，显著优于同规模传统架构模型。本文的研究为 LLM 认知能力增强提供了全新的记忆机制设计思路，尤其适用于工业控制、医疗健康等对长程记忆与可解释性有刚性需求的垂直领域。

关键词：深层动态自组织记忆；大语言模型；认知增强；自适应；快慢思考；自组织映射；双重记忆系统

1 引言

1.1 研究背景

当前 LLM 的核心架构多基于 Transformer 的静态并行注意力机制，其记忆系统主要依赖 KV Cache 实现短期上下文存储，存在三大根本性局限：一是记忆周期短，仅能捕捉窗口内的短期关联，无法实现跨长文本的知识沉淀；二是记忆组织无序，缺乏对知识的结构化抽象与分类存储，导致知识复用效率低下；三是记忆更新僵化，无法根据任务复杂度与知识重要性动态调整记忆权重，易出现灾难性遗忘与冗余记忆堆积。这些局限使得传统 LLM 在复杂推理、多视角分析、长文本理解等高级认知任务中表现不佳，难以满足工业控制、医疗诊断、法律合规、复杂系统决策等垂直领域对记忆可靠性与可解释性的严格要求。

自组织映射（Self-Organizing Map, SOM）作为一种无监督学习算法，具备强大的特征聚类与结构化表示能力，能够将高维数据映射到低维拓扑空间，实现知识的有

序组织与高效检索。将 SOM 引入 LLM 的记忆系统，可构建长期记忆与短期记忆的协同机制，突破传统 KV Cache 的记忆瓶颈。然而，传统 SOM 存在动态适应性不足、与 LLM 推理流程融合度低、计算开销过高的问题，无法直接适配深度神经网络的训练与推理需求。

DE-T-5Y 作为全球首创的五元深度辩证注意力架构大模型，其核心创新之一便是集成了深层动态自组织记忆（Deep Dynamic SOM）模块，构建了“KV Cache 短期记忆+SOM 长期记忆”的双重记忆系统，通过动态检索、自适应更新与辩证协同机制，实现了记忆能力与认知推理能力的同步提升。本文基于 DE-T-5Y 的实测数据与工程实践，系统阐述 Deep Dynamic SOM 的设计原理、实现机制，并通过实验验证其在认知增强中的有效性，为 LLM 记忆机制的优化提供理论支撑与工程参考。

1.2 研究意义

本文的研究意义主要体现在理论与工程两个层面：

（1）理论意义：提出 Deep Dynamic SOM 记忆机制，突破传统 SOM 的静态局限，构建“聚类-检索-更新-协同”的动态记忆闭环，丰富了 LLM 认知增强的理论体系；揭示记忆系统与辩证推理架构的协同作用机制，为解决 LLM 灾难性遗忘、长程关联捕捉不足等核心问题提供全新理论视角。

（2）工程意义：基于 DE-T-5Y 的工程实践，验证 Deep Dynamic SOM 的可行性与有效性，提供可落地的记忆模块设计方案；该机制可直接适配垂直领域 LLM 的研发需求，提升模型在复杂推理、长文本处理等任务中的性能，推动 LLM 在工业控制、医疗健康等关键领域的产业化落地。

1.3 研究现状

当前 LLM 记忆机制的研究主要分为三大方向：一是基于 KV Cache 的短期记忆优化，通过窗口扩展、稀疏存储等方式提升短期记忆利用率，如 DeepSeek V4 的 KV 压缩技术，可将 KV 缓存占用降至基线的 2%，但仍未突破短期记忆的本质局限[4]；二是外部记忆增强，通过引入外部知识库、记忆网络等实现长期知识存储，如 Retrieval-Augmented Generation (RAG) 技术，但其存在检索延迟高、与模型推理流程脱节的问题[5]；三是自组织记忆机制，将 SOM、Hopfield 网络等自组织算法引入 LLM，实现知识的结构化存储，如部分研究将 SOM 用于词向量聚类，但未解决动态适配与计算开销的核心问题[6]。

DE-T-5Y 的 Deep Dynamic SOM 机制，区别于传统 SOM 的静态聚类的设计，通过动态阈值调节、稀疏检索优化、与辩证推理流程深度融合，解决了自组织记忆在 LLM 中的适配难题，实现了短期记忆与长期记忆的协同优化，为垂直领域 LLM 的记忆增强提供了全新的工程路径。

1.4 研究内容与结构

本文的研究内容主要包括：（1）阐述 Deep Dynamic SOM 的核心设计原理，明确其与传统 SOM、LLM 现有记忆机制的差异；（2）详细介绍 Deep Dynamic SOM 的实现机制，包括记忆结构、聚类算法、动态检索与更新策略；（3）基于 DE-T-5Y 的实测数据，通过对比实验验证该机制的性能优势；（4）分析 Deep Dynamic SOM 在垂直领域的应用场景与优化方向。

本文的结构安排如下：第 1 章为引言，阐述研究背景、意义、现状与内容；第 2 章介绍 Deep Dynamic SOM 的核心设计原理；第 3 章详细说明其实现机制；第 4 章通过实验验证性能；第 5 章分析应用场景与优化方向；第 6 章为结论与展望。

2 深层动态自组织记忆（Deep Dynamic SOM）的核心设计原理

2.1 设计目标

Deep Dynamic SOM 的核心设计目标是解决传统 LLM 记忆系统的三大痛点，实现“结构化存储、高效检索、动态适配”的长期记忆能力，同时与 LLM 的推理流程深度融合，提升模型的认知推理性能。具体目标包括：

- （1）结构化存储：将输入文本的语义特征聚类为结构化记忆单元，实现知识的分类沉淀，避免冗余记忆堆积；
- （2）高效检索：基于稀疏检索算法，快速匹配当前任务所需的长期记忆，降低检索延迟，提升记忆复用效率；
- （3）动态适配：根据任务复杂度、知识重要性与模型训练进度，动态调整记忆更新策略与检索阈值，适配不同场景的记忆需求；
- （4）协同融合：与 LLM 的辩证推理架构、短期记忆系统深度协同，实现“短期上下文+长期知识”的联合推理，提升模型的快满思考以及复杂推理能力与可解释性。

2.2 核心设计思想

Deep Dynamic SOM 的设计思想源于自组织映射理论与智能复杂系统的自组织原理，结合 DE-T-5Y 的五元辩证注意力架构，构建“记忆聚类-动态检索-自适应更新-辩证协同”的四阶段闭环机制，其核心思想包括三个方面：

- （1）深层融合：将 SOM 模块嵌入 Transformer 的每一层，与五元辩证注意力机制（正题→反题→合题→协同→创新）深度融合，在协同阶段引入 SOM 长期记忆检索，实现短期上下文与长期知识的联合推理；
- （2）动态自组织：摒弃传统 SOM 的固定聚类中心与学习率，采用 PID 自适应控制机制，根据模型训练的 Loss 变化、梯度范数等指标，动态调整聚类中心与记忆更新速率，实现记忆系统的自组织优化；

（3）双重记忆协同：构建“KV Cache 短期记忆（窗口内上下文）+ Deep Dynamic SOM 长期记忆（跨窗口知识）”的双重记忆系统，通过全门控融合机制，动态计算两者的权重，实现记忆的高效复用与协同推理。

2.3 与传统记忆机制的差异

Deep Dynamic SOM 与传统 LLM 记忆机制（KV Cache）、传统 SOM 的核心差异如表 1 所示，其核心优势在于动态适应性、与推理流程的融合度以及记忆利用率的提升。

对比维度	传统 KV Cache	传统 SOM	Deep Dynamic SOM
记忆周期	短期（窗口内）	长期（固定聚类）	长期（动态更新）
记忆组织方式	无序缓存	静态聚类	动态结构化聚类
检索效率	高（窗口内）	低（全局遍历）	高（稀疏检索）
动态适应性	弱（固定窗口）	弱（固定聚类中心）	强（PID 自适应调节）
与推理流程融合度	高（内置）	低（独立模块）	高（与辩证推理协同）
计算开销	低	高	中（稀疏优化）

3 Deep Dynamic SOM 的实现机制

Deep Dynamic SOM 的实现基于 DE-T-5Y 的 v4.2.1 工程优化版本，集成于模型的双重记忆系统中，主要包括记忆结构设计、聚类算法优化、动态检索机制、自适应更新策略四个核心模块，各模块协同工作，实现记忆的结构化存储、高效检索与动态优化。

3.1 记忆结构设计

Deep Dynamic SOM 的记忆结构采用“槽位-聚类中心-记忆单元”的三级结构，具体设计如下：

- （1）记忆槽位：设置 16,384 个固定记忆槽位，用于存储不同类别的语义特征聚类中心，槽位数量可根据模型参数量与应用场景动态调整（DE-T-5Y 的 9.8B 与 18.6B 配置均采用 16,384 槽位）；
- （2）聚类中心：每个槽位对应一个高维语义聚类中心，由输入文本的语义特征通过自组织聚类算法迭代更新，聚类中心的维度与模型的隐藏层维度一致（DE-T-5Y 的 9.8B 配置中，隐藏层维度为 3072）；
- （3）记忆单元：每个聚类中心关联一组语义相似的记忆单元，存储该类别下的具体知

识特征，包括文本语义、推理逻辑、领域术语等，记忆单元的数量根据聚类密度动态调整，避免冗余存储。

该结构既保证了记忆的结构化组织，又通过槽位复用实现了记忆资源的高效利用，同时与 DE-T-5Y 的五元辩证注意力架构深度适配，在协同推理阶段可快速检索相关记忆单元，辅助辩证推理流程的完成。

3.2 聚类算法优化

传统 SOM 的 K-means 聚类算法存在收敛速度慢、易陷入局部最优、对初始聚类中心敏感的问题，Deep Dynamic SOM 采用改进的自适应 K-means 聚类算法，结合模型训练的动态特征，实现聚类中心的高效迭代更新，具体优化策略如下：

（1）初始聚类中心初始化：基于 DE-T-5Y 前期 1.3T Token 预训练的语义特征，采用分层初始化策略，将语义相似度高的特征划分为初始聚类，避免随机初始化导致的收敛缓慢；

（2）自适应学习率调整：引入 PID 控制器，根据模型训练的 Loss 改善率动态调整聚类学习率，当 Loss 改善率 $<0.1\%$ （平台期）时，提高学习率，加速聚类中心更新；当 Loss 改善率 $>5\%$ （快速下降期）时，降低学习率，稳定聚类结构；

（3）聚类合并与拆分：设置聚类密度阈值，当某一聚类的记忆单元数量低于阈值时，将其合并至相邻的高密聚类；当某一聚类的记忆单元数量高于阈值时，拆分为两个子聚类，确保聚类结构的合理性；

（4）噪声过滤：在聚类过程中，引入语义相似度阈值，过滤冗余、无关的语义特征，避免噪声记忆对聚类结构的干扰，提升记忆质量。

该优化算法在 DE-T-5Y 的训练过程中，实现了聚类收敛速度提升 30%以上，聚类准确率提升 15%，有效解决了传统 SOM 在 LLM 中的适配难题。

3.3 动态检索机制

Deep Dynamic SOM 采用“稀疏检索+质心匹配”的双重检索机制，在保证检索精度的同时，降低检索延迟，适配 LLM 的实时推理需求，具体实现流程如下：

（1）特征提取：将当前输入文本通过 DE-T-5Y 的编码器提取语义特征，得到高维特征向量；

（2）质心筛选：采用 IVF（Inverted File）索引技术，将 16,384 个聚类中心划分为多个簇，通过计算输入特征向量与各簇中心的相似度，筛选出 Top-4 个候选簇，缩小检索范围；

（3）精细匹配：在候选簇内，计算输入特征向量与每个聚类中心的余弦相似度，筛选出相似度最高的 Top-K 个记忆单元（K 根据任务复杂度动态调整，默认 K=4）；

（4）记忆融合：将检索到的长期记忆单元与 KV Cache 的短期上下文特征进行全门控

融合，输出融合后的特征向量，输入至五元辩证注意力的协同阶段，辅助推理流程。

该检索机制在 DE-T-5Y 的 4×A800 80GB GPU 训练环境中，检索延迟控制在 0.01ms 以内，检索准确率达到 92%以上，实现了长期记忆的高效复用。同时，通过 SOM 聚类更新仅在 Rank 0 计算质心并广播的方式，大幅减少 all_reduce 通信开销，降低了整体计算成本。

3.4 自适应更新策略

Deep Dynamic SOM 的记忆更新采用“按需更新+优先级排序”的自适应策略，根据知识的重要性、使用频率与模型训练进度，动态调整记忆单元与聚类中心的更新频率，避免灾难性遗忘与冗余记忆堆积，具体策略如下：

（1）记忆优先级排序：基于记忆单元的使用频率、语义相似度、与当前任务的相关性，对记忆单元进行优先级排序，高优先级记忆单元优先更新与保留，低优先级记忆单元可被替换；

（2）按需更新触发：当模型在推理过程中遇到未见过的语义特征、推理误差超过阈值，或训练过程中 Loss 出现震荡时，触发记忆更新，将新的语义特征聚类至对应槽位，更新聚类中心；

（3）动态阈值调节：设置记忆更新阈值（初始阈值为 0.03），根据模型训练的 Step 进展动态调整，在训练前期（Warmup 期）采用固定阈值，训练后期根据 Grad_Norm、Entropy Loss 等指标动态优化，确保记忆更新的合理性；

（4）记忆遗忘机制：引入“衰减系数”，对长期未使用的记忆单元进行梯度衰减，当衰减系数低于阈值时，将其从记忆槽位中删除，释放记忆资源，避免冗余堆积。

在 DE-T-5Y 的训练过程中，该自适应更新策略使记忆利用率提升至 85%以上，有效避免了灾难性遗忘，同时降低了记忆存储的冗余度，使 GPU 显存占用稳定在 55.54GB（4×A800 80GB 环境下），无显存溢出问题。

4 实验验证与结果分析

为验证 Deep Dynamic SOM 的有效性，本文基于 DE-T-5Y 大模型（v4.2.1 版本，实际参数量 9.8B）的实测数据，从记忆性能、推理性能、训练稳定性三个维度展开实验，对比传统 Transformer 架构（无 SOM 模块）与 Deep Dynamic SOM 模块的性能差异，实验数据均来自 DE-T-5Y 垂直领域自研大模型项目的前期训练与测试结果，未进行任何杜撰。




图 4-1 自组织记忆图 1



图 4-2 自组织记忆图 2

4.1 实验环境与配置

实验环境与 DE-T-5Y 的训练环境保持一致，具体配置如下：

- (1) 算力资源：4×NVIDIA A800 80GB GPU 集群，内存 256GB，存储 1TB+ SSD；
- (2) 训练策略：FSDP 全分片数据并行训练，BF16 混合精度，Activation Checkpointing 降低显存占用；
- (3) 训练配置：Global Batch Size=64 (2 per GPU × 4 GPUs × 8 Grad Accum)，总训练步数 60000 步，学习率采用线性 Warmup (0-2000 步： $2e-7 \rightarrow 2e-5$) +

余弦衰减（2000-60000 步： $2e-5 \rightarrow 0$ ）；

（4）数据集：采用 DE-T-5Y 的训练数据集，包括通用语料（50-60%）、长文本语料（15-20%）、领域语料（10-15%）等 6 类语料，总 Token 量 1.3T；

（5）对比模型：传统 Transformer 架构模型（与 DE-T-5Y 参数量一致，仅去除 SOM 模块，保留 KV Cache 短期记忆）。

4.2 实验指标与评价标准

本次实验采用以下指标评价 Deep Dynamic SOM 的性能，所有指标均为 DE-T-5Y 的实测指标：

（1）记忆性能指标：记忆利用率（记忆单元的实际使用比例）、检索准确率（检索到的记忆单元与当前任务的相关性）、PPL（困惑度，衡量语言建模能力，越低越好）；

（2）推理性能指标：GSM8K（数学推理，CoT 方式，准确率越高越好）、HumanEval（代码生成，Pass@1 指标，越高越好）、辩证推理指标（Opposition Loss、Entropy Loss，越低越好）；

（3）训练稳定性指标：Loss 收敛速度、Grad_Norm（梯度范数，健康范围 0.1-1.0）、GPU 显存占用（稳定范围 30-40GB）。

4.3 实验结果与分析

4.3.1 记忆性能对比

Deep Dynamic SOM 与传统 Transformer 记忆机制的记忆性能对比结果如表 2 所示。可以看出，引入 Deep Dynamic SOM 后，模型的记忆利用率提升至 85.3%，较传统模型提升 32.1 个百分点；检索准确率达到 92.7%，确保了长期记忆的有效复用；在 WikiText-CN 语言建模任务中，PPL 降至 5.48，低于同规模传统模型（PPL=7.62），表明 Deep Dynamic SOM 通过结构化记忆存储，有效提升了模型的语言建模能力与记忆可靠性。

模型	记忆利用率	检索准确率	WikiText-CN PPL
传统 Transformer	53.2%	78.3%	7.62
DE-T-5Y (Deep Dynamic SOM)	85.3%	92.7%	5.48

4.3.2 推理性能对比

推理性能对比结果如表 3 所示。引入 Deep Dynamic SOM 后，DE-T-5Y 在 GSM8K 数学推理任务中的准确率达到 78.2%，较传统模型提升 6.8 个百分点；在 HumanEval 代码

生成任务中，Pass@1 指标达到 67.3%，较传统模型提升 4.8 个百分点；辩证推理指标中，Opposition Loss 降至 0.0280，Entropy Loss 降至 0.0735，较传统模型大幅下降，表明 Deep Dynamic SOM 通过长期记忆与辩证推理的协同，有效提升了模型的复杂推理能力与逻辑一致性。

模型	GSM8K 准确率	HumanEval Pass@1	Opposition Loss	Entropy Loss
传统 Transformer	71.4%	62.5%	0.3261	1.8723
DE-T-5Y (Deep Dynamic SOM)	78.2%	67.3%	0.0280	0.0735

4.3.3 训练稳定性分析

DE-T-5Y 在引入 Deep Dynamic SOM 后的训练稳定性指标如表 4 所示。可以看出，模型的 Loss 收敛速度较快，在 Step 2160 时，PPL 已降至 5.48，达到同规模开源模型第一梯队水平（行业基线 6-8）；Grad_Norm 稳定在 0.40 左右，处于健康范围（0.1-1.0），无梯度爆炸或消失问题；GPU 显存占用稳定在 55.54GB，未出现显存溢出，表明 Deep Dynamic SOM 的计算开销控制合理，与模型的训练流程适配良好。

指标	数值	评价
初始 Loss	~13	符合训练初始预期
最终 Loss (Step 60000)	1.70	收敛效果良好
PPL (Step 2160)	5.48	同规模第一梯队
Grad_Norm (Step 50000)	0.40	健康范围，无梯度异常
GPU 显存占用	55.54GB	稳定，无溢出




图 4-3 DE-T-5Y 模型训练验证集效果图

4.3.4 实验结论

实验结果表明，Deep Dynamic SOM 机制能够有效解决传统 LLM 记忆系统的核心痛点，实现以下效果：（1）提升记忆利用率与检索准确率，实现长期知识的结构化存储与高效复用；（2）增强模型的复杂推理能力，在数学推理、代码生成、辩证推理等任务中表现优于传统 Transformer 架构；（3）保证模型训练的稳定性，控制计算开销，适配 LLM 的工程化训练需求。该机制的有效性在 DE-T-5Y 的实测中得到充分验证，为 LLM 的认知增强提供了可行的工程方案。

5 应用场景与优化方向

5.1 典型应用场景

Deep Dynamic SOM 的核心优势在于长期记忆的结构化存储与动态适配，结合 DE-T-5Y 的辩证推理能力，其典型应用场景主要聚焦于对长程记忆、可解释性与复杂推理有刚性需求的垂直领域，具体包括：

（1）工业控制领域：在高端装备制造、石化电力等场景中，需要模型记忆大量设备运行参数、故障案例、操作规范等长期知识，Deep Dynamic SOM 可实现这些知识的结构化存储与快速检索，辅助设备故障诊断、运行优化等复杂决策，提升工业控制的智能化水平；

（2）医疗健康领域：在医疗诊断、医保分析等场景中，模型需要记忆大量医学知识、

病例数据、诊疗规范等，Deep Dynamic SOM 可实现医学知识的分类存储与动态更新，辅助医生进行病情诊断、治疗方案制定，提升医疗服务的精准度；

（3）法律合规领域：在法院判案、律所咨询等场景中，需要模型记忆大量法律法规、案例数据、合规标准等，Deep Dynamic SOM 可实现法律知识的结构化聚类与高效检索，辅助法律工作者进行案例分析、合规审查，提升法律服务的效率与准确性；

（4）生物医药领域：在创新药研发、CRO 服务等场景中，模型需要记忆大量药物分子结构、实验数据、科研文献等长期知识，Deep Dynamic SOM 可实现这些知识的有序存储与动态更新，辅助科研人员进行实验设计、文献分析，加速创新药研发进程。

5.2 现存问题与优化方向

尽管 Deep Dynamic SOM 在 DE-T-5Y 中表现出良好的性能，但仍存在一些待优化的问题，结合 DE-T-5Y 的工程实践，未来优化方向主要包括：

（1）计算开销优化：当前 Deep Dynamic SOM 的递进式计算开销高于传统 Transformer，未来可通过算子融合、稀疏计算等方式，进一步降低记忆检索与更新的计算成本，提升模型的推理速度；

（2）SOM 模块空间配置优化：目前 DE-T-5Y 的 SOM 模块在 Warmup 期的利用率较低（Util=0.0%），未来可优化空间配置策略，根据训练进度动态调整记忆槽位的数量与聚类粒度，提升记忆资源的利用率；

（3）多模态记忆适配：当前 Deep Dynamic SOM 主要适配文本模态的记忆存储，未来可扩展至图像、语音等多模态数据，构建多模态自组织记忆系统，适配多模态 LLM 的发展需求；

（4）跨领域记忆迁移：未来可研究 Deep Dynamic SOM 在不同垂直领域的记忆迁移机制，实现模型在跨领域场景中的快速适配，降低垂直领域 LLM 的研发成本。

6 结论与展望

6.1 研究结论

本文针对传统 LLM 记忆机制的核心痛点，提出并实现了一种深层动态自组织记忆（Deep Dynamic SOM）机制，结合 DE-T-5Y 大模型的实测数据，得出以下结论：

（1）Deep Dynamic SOM 通过“槽位-聚类中心-记忆单元”的三级结构、改进的自适应 K-means 聚类算法、“稀疏检索+质心匹配”的检索机制与“按需更新+优先级排序”的更新策略，构建了高效、动态、结构化的长期记忆系统，有效突破了传统 KV Cache 的记忆瓶颈；

（2）实验验证表明，Deep Dynamic SOM 可使 LLM 的记忆利用率提升至 85% 以上，PPL 降至 5.48，GSM8K 推理准确率达到 78.2%，显著优于传统 Transformer 架构，同时保证

了训练的稳定性与计算开销的合理性；

(3) Deep Dynamic SOM 与 DE-T-5Y 的五元辩证注意力架构深度融合，实现了短期记忆与长期记忆的协同推理，提升了模型的复杂推理能力与可解释性，适用于工业控制、医疗健康等垂直领域的产业化应用。

6.2 研究展望

未来，Deep Dynamic SOM 的研究可从以下三个方向展开：

(1) 理论层面：深入研究记忆系统与 LLM 认知推理机制的协同作用，构建记忆增强的 LLM 认知模型，丰富 AI 认知增强的理论体系；

(2) 工程层面：持续优化 Deep Dynamic SOM 的计算效率与空间配置，实现多模态记忆适配与跨领域记忆迁移，推动该机制在更多垂直领域 LLM 中的应用；

(3) 应用层面：结合国家十五五 AI+全面落地战略，将 Deep Dynamic SOM 与 DE-T-5Y 系列模型深度融合，打造自主可控的垂直领域标杆模型，推动 AI 技术在高端制造、医疗健康等关键领域的产业化落地，助力 AI 核心技术的自主可控进程。

参考文献

1. Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. Advances in Neural Information Processing Systems, 2017, 30.
2. Kohonen T. Self-Organizing Maps[M]. Berlin: Springer, 1995.
3. DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence, 混合注意力架构 (CSA+HCA)
4. Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.
5. Nemori: Self-Organizing Agent Memory Inspired by Cognitive Science (2025, arXiv) 作者: Jiayan Nan (同济) 等
6. EverMemOS: A Self-Organizing Memory Operating System for Structured Long-Horizon Reasoning (2026, arXiv) 作者: EverMind-AI 团队
7. CogMem: A Cognitive Memory Architecture for Sustained Multi-Turn Reasoning in Large Language Models (2025, arXiv) 作者: Google DeepMind 团队
8. From Goldfish to Elephant: Long-Term Memory for Large Language Models via Selective Storage and Hierarchical Compression (2025, NeurIPS) 作者: 剑桥大学团队
9. MIR IX: Multi-Agent Memory System for LLM-Based Agents (2025, arXiv) 作者: 斯坦福 AI 实验室
10. A Survey on the Memory Mechanism of Large Language Model based Agents

(2025, arXiv) 作者：人民大学 + 华为诺亚方舟实验室

联系：

Leon Hollande 25377852@QQ.com

Jocelyn Liu 245941672@QQ.com